VYSOKÉ UČENÍ TECHNICKÉ V BRNĚ

Fakulta informačních technologii

IFJ A IAL

2019/2020

PROJEKT

Tým 018, varianta II

Členové týmu:

Matej Hockicko (xhocki00)

Tomáš Julina (xjulin08) - vedoucí

Tomáš Kantor (xkanto14)

Lukáš Kuchta (xkucht09)

Rozdělení bodů:

xhocki00: 25%

xjulin08: 25%

xkanto14: 25%

xkucht09: 25%

Rozdělení práce:

Práci na projektu jsme si rozdělili rovnoměrně (každý 25%), kvůli rozsahu se určil jeden člen týmu na každý modul s tím, že v případě problému jsme jej řešili společně. Konkrétní práce členů na jednotlivých částech jsou uvedený níže:

Matej Hockicko – generování cílového kódu (+ pomocné struktury), běhové kontroly, testování, dokumentace

Tomáš Julina – vedení týmu, lexikální analýza (+ pomocné struktury), testování, dokumentace

Tomáš Kantor – syntaktická analýza (+ pomocné struktury), sémantická analýza (+ pomocné struktury), testování, dokumentace

Lukáš Kuchta – sémantická analýza (výrazy + pomocné struktury), testování, dokumentace

Komunikace:

Pro komunikaci při vývoji jsme využívali výhradně týmových chat v aplikaci Messenger či časté osobní schůzky.

Verzovací systém

Při vývoji jsme pro verzování a vzájemnou spolupráci používali verzovací systém *Git* se vzdáleným repozitářem na *Github.com.*

Tento postup nám umožnil pracovat na více modulech současně a v případě chyby v programu jsme se mohli snadno vrátit na předchozí verzi.

Popis návrhu:

Řešení projektu jsme si rozdělili do dílčích modulů, které mezi sebou komunikují postupem, který je popsán níže. Projekt jsme začali řešit na začátku semestru, prvním krokem byla lexikální analýza, poté jsme již zbylé moduly na základě předávaných tokenů tvořili simultánně.

1. Lexikální analýza

Lexikální analýza (scanner) byl vytvořen na základě návrhu konečného automatu (viz. přílohy), konečný automat je v kódu implementován ve funkci *getToken* s využitím příkazu *switch* a jednotlivým stavům automatu odpovídají *case*.

Scanner dále komunikuje se syntaktickou analýzou prostřednictvím pomocné struktury *TokenPTR*, který představuje předávaný token, tato struktura obsahuje veškeré informace o konkrétním tokenu – jeho hodnotu, typ, alokovaný prostor, atd... Scanner postupně načítá jednotlivé znaky ze vstupu (*stdin*) dokud neprojde do koncového stavu, v tomto případě posílá hotový token, v opačném případě dochází k chybě s kódem 1.

Pro zpracování *INDENT* a *DEDENT* (odsazení) byla vytvořena pomocná struktura *iStack* (indent stack), do kterého se při odsazování ukládá aktuální úroveň odsazení a počet mezer v odsazení, zároveň byla použita statická proměnná, která slouží k poznačení si, zda je aktuálně zpracovávaný token prvním na řádku, či nikoliv, tyto informace jsou následně využity pro odsazování a vracení se z odsazení.

Pro ESCAPE sekvence je použita statická proměnná, díky který lze zkontrolovat, zda byl předchozí znak „\“ či nikoliv.

2. Syntaktická a sémantická analýza

Syntaktická analýza

Syntaktická analýza je založená na LL gramatice, která je simulována pomocí rekurzivního sestupu. Pomocí funkce *getToken* žádá další token od lexikální

analýzy. Pro zajištění, aby se příkaz return nevyskytoval mimo tělo funkce, používáme proměnnou *inFuncDef*. Není snadné rozhodnout, zda se jedná o výraz, přiřazení výrazu, nebo přiřazení volání funkce, v případě tokenu *id*. Používáme funkci *preloadToken*. Tato funkce nám sdělí, který token by byl další. Pokud bychom použili pouze funkci *getToken*, ztratili bychom token, který potřebuje precedenční analýza.

Pro zpracování výrazů byla využitá precedenční syntaktická analýza zdola nahoru. Byla vytvořena funkce *expression*, v které je cyklus, který se opakuje, dokud výraz není zpracován na konečný výsledek, který je následně vrácen parseru. Funkce využívá pomocnou datovou strukturu zásobník *TStackToken*, na který si ukládá položky struktury *TStackTokenItem*, ve které jsou informace o operandech a operátorech jako například datový typ a typ tokenu. Funkce volá pomocné funkce *shift* (slouží na „pushování“ položek na zásobník) a *reduce* (slouží na vyhodnocování podvýrazů). Funkce *reduce* využívá funkce *test_rule* (vrací pravidlo pro vyhodnocení podvýrazu) a *semantic* (vykonává sémantické kontroly operandů a operátorů a taktéž volá funkce na generování cílového kódu).

Sémantická analýza

Informace o proměnných a jejich typech jsou ukládány do tabulky symbolů. Stejně tak informace o funkcích, zda byly definovány, počet parametrů atp. Tyto informace jsou následně využívány ke kontrolám definic a redefinic. Taktéž kontrolujeme, zda byly definovány funkce před jejich volání z hlavního těla programu včetně funkcí, na kterých jsou závislé. Dále kontrolujeme práci s globální a zároveň lokální proměnnou stejného jména ve funkci. K tomu slouží proměnná *reviewed* v tabulce symbolů spolu s funkcí *unreviewVariables*.

3. Generování cílového kódu

Při tvorbě generátoru cílového kódu bylo potřeba několik pomocných struktur. Hlavní strukturou při generovaní byl seznam instrukcí, do kterého bylo možné vkládat na libovolné místo. Této možnosti jsme využili zejména při vkládaní definic funkcí před hlavní tělo programu, ale taktéž u větvení příkazu, nebo u cyklu *while*. Dále bylo nutno vytvořit dvě pomocné datové struktury typu *stack*, z kterých jedna byla použita na ukládaní indexů aktuálně zpracovávaných *if-else* částí, aby bylo následně možné provést skoky na jednotlivé *if-else* instrukce, kdežto druhá struktura sloužila na ukládaní pozic v

seznamu instrukcí, pomocí kterých generátor vkládal instrukce na správná místa, tedy před, do nebo za tělo *while* cyklu, nebo také do různých části konstrukce *if-else*.

Komunikace generátoru s ostatními moduly probíhala jako volání některé funkce z generátoru, v reakci na což generátor přidal určité instrukce do seznamu, nebo vrátil chybu při nezdařené alokaci. Potřebné operandy instrukcí se do generátoru dostávaly jako odkazy z tabulky symbolů, z kterých si generátor vzal podstatné informace a ty vložil do struktury "*Instr*", která byla zároveň položkou v seznamu instrukcí.

Pro moduly pod generátorem byly určené zejména funkce na generováni konstrukce *if-else* a *while*, jednotlivé funkce pro generovaní do určité části (*generate_if*, *generate_else*, …) nebo také funkce pro přímé generování libovolné instrukce. Nesměly také chybět funkce pro generovaní definice, ukončení, voláni funkce a také pro práci s návratovou hodnotou funkce.

Úlohou generátoru bylo také vygenerovat vestavěné funkce. Toto generovaní probíhalo hned na začátku, kdy byla zavolána funkce „*generator_start*". Po jejím zavoláni se vygenerovaly vestavěné funkce spolu s několika pomocnými proměnnými, které sloužily pro případné konverze a kontrolu typů za běhu programu.

Kontrola typů probíhala před generováním jednotlivých instrukcí a to tak, aby již vygenerovaná instrukce obsahovala implicitně konverzované operandy, nebo aby se interpret ukončil s návratovým kódem již před vykonáním samotné instrukce.

Speciální algoritmy a datové struktury:

1. **Dynamický řetězec**

Pro ukládání obsahu (řetězce) tokenu do jeho struktury bylo zapotřebí implementovat dynamický řetězec, jelikož délka obsahu není předem známá.

Při vytvoření nového nového tokenu se alokuje prostor pro dynamický řetězec o základní velikosti 8, následně se při zápisu každého znaku ve funkci *updateDynamicString* kontroluje, zda při zápisu nebude velikost alokovaného prostoru přesažena, v případě, že ano, alokuje (pomocí *realloc*) se další „chunk“ (velikost alokovaného prostoru zvětšíme o 8).

2. **Dynamický indent stack**

Pro zpracování zanoření se (*indent*) a následného vynoření (*dedent*) bylo nutné ukládat si hodnotu aktuálního zanoření a zároveň i hodnoty předchozích zanoření. Proto nebylo nic jednoduššího, než vytvořit pomocnou (dynamickou) datovou strukturu *iStack,* tato obsahuje informaci o aktuální úrovni zanoření, počtu mezer a také odkaz na další položku zásobníku. Zásobník také obsahuje pomocné funkce pro práci s ním *initStack* (inicializace zásobníku), *pushStack* (uložení nové hodnoty do zásobníku), *popStack* (odstranění aktuální hodnoty z vrcholu zásobníku), *destroyStack* (zrušení celého zásobníku a uvolnění paměti).

3. **Tabulka symbolů**

Tabulku symbolů jsme implementovali ve formě tabulky s rozptýlenými položkami (hash table). Synonyma jsou zřetězena pomocí lineárního seznamu. Velikost tabulky jsme zvolili číslo 1549. Jedná se o prvočíslo. To nám umožní lepší rozptýlení položek. Dále toto číslo nabízí výhodný poměr mezi časovou a paměťovou náročností.

Každá položka obsahuje unikátní klíč v podobě řetězce, kterým je název proměnné nebo funkce a ukazatel na další položku.

Funkce obsahují informace o počtu parametrů s vyhrazenou hodnotou pro libovolný počet parametrů. Proměnnou pro definici funkce, a proměnnou

reviewed sloužící ke kontrolám vzájemných závislostí funkcí. Položka obsahuje i ukazatel na lokální tabulku symbolů. Proměnné obsahují informaci o jejich typu.

Tabulka poskytuje následující funkce. *Htab_init* pro inicializaci tabulky, *htab_insert* pro vložení položky do tabulky, *htab_find* pro vyhledání položky pomocí klíče (*key*), *htab_free* pro uvolnění paměti tabulky.

Přílohy:

Diagram konečného automatu specifikující lexikální analyzátor

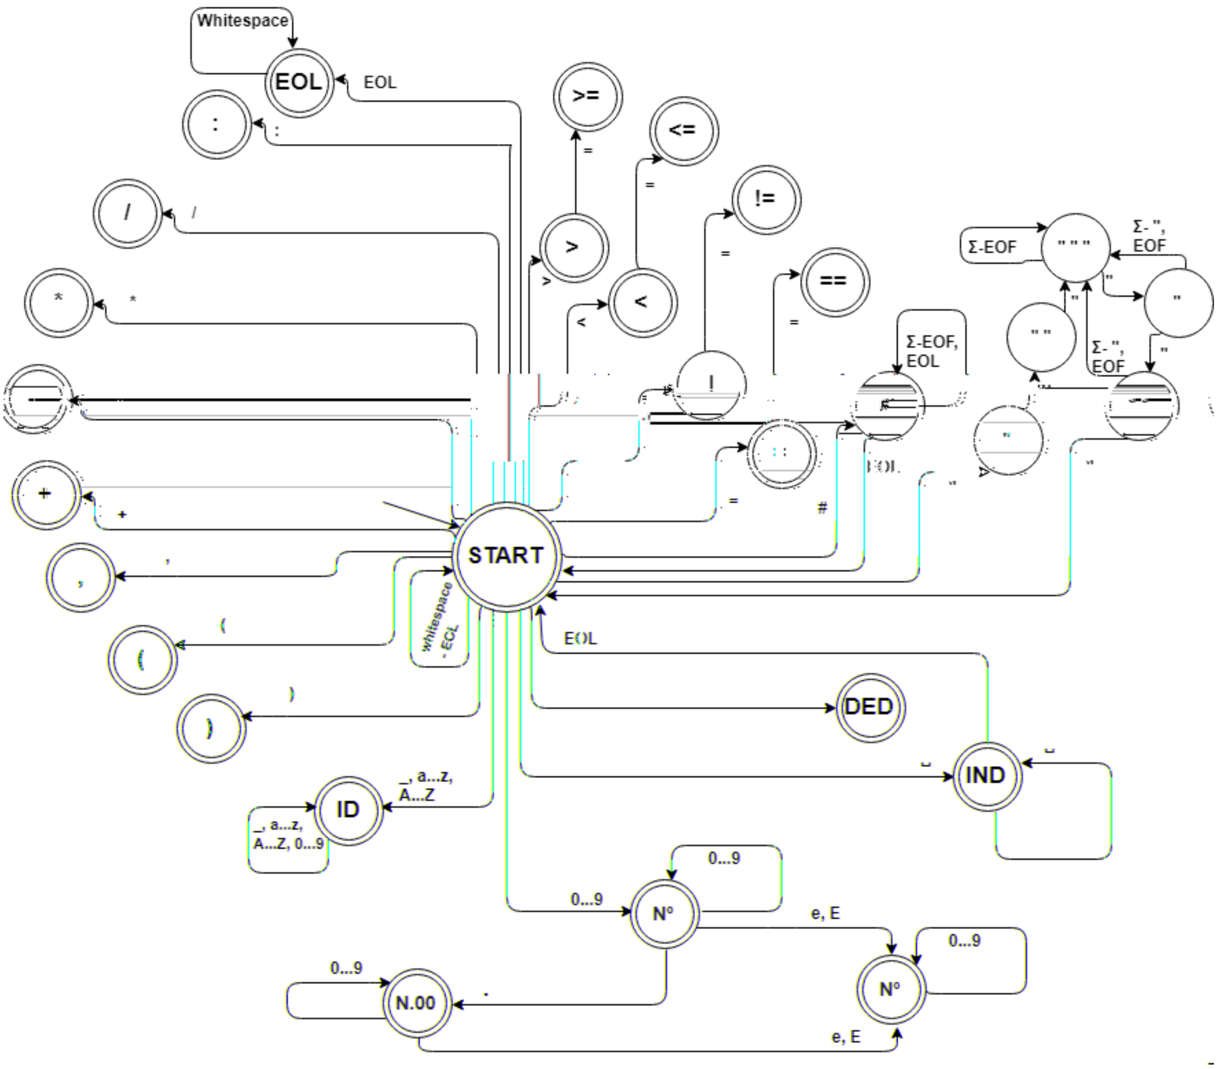

LL – gramatika

1. Program -> FuncDec Program
2. Program -> Stat Program
3. Program -> eof
4. FuncDec -> def id (ParamList) : eol indent Stat StatList dedent
5. ParamList -> ε
6. ParamList -> Param ParamList2
7. ParamList2 -> , Param ParamList2
8. ParamList2 -> ε
9. Param -> id
10. Param -> int
11. Param -> double
12. Param -> string
13. StatList -> Stat StatList
14. StatList -> ε
15. Stat -> FuncCall eol
16. Stat -> Expression eol
17. Stat -> id eq Assignment
18. Stat -> pass eol
19. Stat -> if (Expression) : eol indent StatList dedent else indent StatList dedent
20. Stat -> while (Expression) : eol indent StatList dedent
21. FuncCall -> id (ParamList)
22. Assignment -> FuncCall eol
23. Assignment -> Expression eol
24. Param -> None

LL – tabulka

	)	(	id	dedent	while	if	pass	string	double	int	none	,	def	eof
<program>			2		2	2	2	2	2	2	2		1	3
<funcDef>													4	
<paramList>	5		6					6	6	6	6			
<paramList2>	8											7		
<param>			9					12	11	10	24			
<statList>			13	14	13	13	13	13	13	13	13			
<stat>		16	15,16,17		20	19	18							
<funcCall>			21											
<assignment>		23	22,23					23	23	23	23			

Precedenční tabulka

	+-	*/	//	r	(	)	i	$
+-	>	<	<	>	<	>	<	>
*/	>	>	>	>	<	>	<	>
//	>	<	>	>	<	>	<	>
r	<	<	<		<	>	<	>
(	<	<	<	<	<	=	<	
)	>	>	>	>		>		>
i	>	>	>	>		>		>
$	<	<	<	<	<		<	

r- relační operátory == != <= < >= >

i- (id, int, double, string)